LHS QUANT LAB · GUIA DE MÉTODO

Os critérios de aprovação de um backtest

O que cada critério mede, como é calculado, por que o limite é aquele e como ler o resultado — com exemplos dos backtests que já fizemos no laboratório.

Um setup só é **aprovado** quando passa em **todos** os critérios. Basta um falhar para ele ser reprovado.

Versão de 20/10/2026 · Exemplos: backtests 001 a 004.1 (EURUSD)

ANTES DOS CRITÉRIOS

Cinco ideias que aparecem em todos

1. R — a unidade de resultado

1 R é o quanto você perde se o stop for atingido. Se o stop está a 20 pips da entrada, 1 R = 20 pips. Uma operação que ganha 30 pips nesse caso rendeu +1,5 R. Medir em R deixa todos os setups comparáveis, qualquer que seja o tamanho do stop, o par ou o tempo gráfico. Com 1% do capital arriscado por operação, +1 R = +1% da conta.

2. Sem custos × líquido

Sem custos é o resultado só com o movimento do preço. **Líquido** desconta spread (de cada barra), slippage (2 pontos por lado) e comissão. A diferença mostra o quanto o custo come: se o setup só ganha sem custos, ele tem vantagem, mas não paga a conta.

3. Dentro × fora da amostra

Dentro da amostra (treino) é o período usado para escolher parâmetros. **Fora da amostra** é o período que o setup nunca viu. **Todos os critérios são aplicados fora da amostra**, porque é o único resultado honesto: dentro da amostra, qualquer setup otimizado parece bom.

4. Walk-forward

Em vez de uma única divisão treino/teste, repete o processo: otimiza em 36 meses, opera os 6 seguintes, anda 6 meses e repete. Junta muitos anos de resultado fora da amostra e imita o trader que reotimiza de tempos em tempos.

5. Sem look-ahead

O sinal só usa dados da **barra já fechada**; a entrada é na abertura da barra seguinte (ou numa ordem stop com preço conhecido antes). Usar informação do futuro é o erro mais comum — e o que mais infla resultados.

RESUMO DOS 7 CRITÉRIOS

#	Critério	Regra	Pergunta que responde
1	Número de operações	≥ 100 fora da amostra	Há dados suficientes para concluir algo?
2	Expectativa	> 0 R líquida	Ganha dinheiro depois dos custos?
3	Fator de lucro	> 1,2	A margem é grande o bastante para aguentar a vida real?
4	Melhor que o acaso	$p < 0,05$	O sinal acrescenta algo ou é sorte?
5	PBO	< 0,5	A otimização encontrou algo real ou só se ajustou ao ruído?
6	Drawdown anual	nenhum ano < −20%	Dá para aguentar emocional e financeiramente?
7	Frequência	≥ 2/semana e p90 ≤ 5 dias úteis	Funciona como day trade de verdade?

01 Número de operações

`≥ 100 operações fora da amostra`

O que mede: se existe amostra suficiente para separar habilidade de sorte.

Por que 100: o resultado médio de poucas operações oscila muito. Com 30 operações, um setup sem vantagem nenhuma pode facilmente mostrar +0,2 R de média só por acaso. Com 100 ou mais, essa oscilação cai para menos da metade (ela diminui com a raiz do número de operações). 100 é o mínimo; quanto mais, melhor.

EXEMPLO REPROVADO
003 (Bollinger, H4): +0,105 R fora da amostra, mas com só **36 operações** em quase 6 anos. Bonito, mas inconclusivo.

EXEMPLO APROVADO
004.1 (rompimento da Ásia, H1): **1.069 operações** em 13 anos fora da amostra.

Armadilha: desconfie de resultado excelente com poucas operações — é o mais comum em vídeos e prints.

02 Expectativa líquida

`Expectativa > 0 R, já com custos`

O que mede: quanto o setup ganha (ou perde), em média, **por operação**, depois de spread, slippage e comissão.

Como calcula: média dos resultados em R. Equivalente a `taxa de acerto × ganho médio − taxa de erro × perda média`.

Por que importa: é o critério mais direto. Taxa de acerto alta não basta: o M15 do 003 acertava 58% das vezes e perdia dinheiro, porque o ganho médio era bem menor que a perda média.

CUSTOS MATANDO A VANTAGEM
002.1 (M15): ≈ 0 R sem custos e −0,24 R líquido — o custo de ~0,2 R por operação decidiu tudo.

POSITIVO, MAS FINO
004.1 (H1): +0,105 R sem custos e +0,020 R líquido.

Armadilha: olhar só o resultado sem custos. Sempre compare as duas linhas.

03 Fator de lucro

`Fator de lucro > 1,2`

O que mede: quanto o setup ganha para cada 1 que perde. **`soma dos ganhos ÷ soma das perdas`**. 1,0 é empate; 1,5 significa que os ganhos somam 50% a mais que as perdas.

Por que 1,2 e não 1,0: é a **margem de segurança**. Na vida real, o resultado costuma ser pior que no backtest: slippage maior em notícias, spreads diferentes, dias sem operar, erros de execução, e a própria vantagem tende a encolher com o tempo. Um setup com fator 1,04 vira prejuízo com pouca coisa dando errado.

> **EXEMPLO**
> 004.1: expectativa positiva (+0,020 R), mas fator de lucro **1,04**. Com comissão de US$ 7 por lote, já fica negativo — exatamente o que o critério tenta evitar.

Armadilha: fator de lucro altíssimo (acima de 3) com poucas operações costuma ser sorte ou look-ahead.

04 Melhor que o acaso

`p-valor < 0,05 contra entradas aleatórias`

O que mede: se o **sinal** acrescenta alguma coisa, ou se qualquer entrada com as mesmas regras de saída daria o mesmo resultado.

Como calcula: simulamos 300 versões do setup em que o sinal é trocado pelo acaso — mantendo tudo o mais igual (mesmos dias, mesmo stop, mesmo alvo, mesmos custos). No rompimento da Ásia, sorteamos a **direção** (cara ou coroa); no Bollinger, sorteamos o **momento** de entrada. O **p-valor** é a fração das simulações aleatórias que foram tão boas quanto o setup real. p = 0,017 quer dizer que só 1,7% das versões aleatórias empataram ou venceram.

Por que 0,05: é o limite usual em estatística: aceitamos no máximo 5% de chance de o resultado ser sorte.

> **PASSOU**
> 004.1: setup +0,020 R × aleatório −0,060 R (p = 0,017). A direção do rompimento carrega informação.

> **PASSAR NÃO BASTA**
> 002.1: p = 0,04, mas o setup perdia −0,22 R e o aleatório −0,26 R. Ele só perdia menos que o acaso.

Armadilha: esse critério sozinho não aprova nada — ele diz se há sinal, não se o sinal paga os custos.

05 PBO — probabilidade de sobreajuste

`PBO < 0,5`

O que mede: quando testamos muitas combinações de parâmetros e escolhemos a melhor, ela é melhor de verdade ou só teve sorte naquele período? O PBO (*Probability of Backtest Overfitting*, Bailey et al.) responde a isso.

Como calcula (método CSCV): dividimos o histórico em 10 blocos e testamos as 252 formas de usar metade deles como treino e a outra metade como teste. Em cada uma, pegamos a combinação campeã do treino e vemos em que posição ela fica no teste. **PBO = fração das vezes em que a campeã fica abaixo da mediana no teste.**

Por que 0,5: 0,5 é o que se espera de pura sorte (a campeã cai na metade de baixo metade das vezes). Abaixo disso, a escolha tem algum valor; perto de 0, as campeãs continuam fortes fora do treino.

SOBREAJUSTE
002.1: PBO = 0,77 — a campeã do treino caía na metade de baixo em 77% das vezes.

ESCOLHA CONSISTENTE
004.1: PBO = 0,12 — as combinações que lideram tendem a continuar acima da mediana.

Armadilha: quanto mais combinações você testa, maior a chance de achar uma "ótima" por acaso. Grades pequenas e PBO baixo andam juntos.

06 Drawdown anual

`Nenhum ano com drawdown pior que −20%`

O que mede: a maior queda da conta, do topo até o fundo, **dentro de cada ano**, arriscando 1% por operação.

Por que importa: um setup lucrativo no total pode ser impossível de operar. Depois de perder 20% em poucos meses, quase todo trader abandona o método (ou aumenta o risco para recuperar, o que é pior). E perdas crescem exponencialmente: para recuperar −20% é preciso +25%; para recuperar −50%, +100%.

REPROVADO
002.1: pior ano com −57% (2024).

APROVADO, COM RESSALVA
004.1: pior ano com −14,7%. Mas os anos ruins se encadearam (2016–2021) e a queda total do período chegou a −48%.

Armadilha: olhar só o drawdown anual pode esconder sequências de anos ruins. Por isso o relatório mostra também o drawdown máximo do período inteiro e a curva de capital.

07 Frequência de day trade

`≥ 2 operações por semana e intervalo p90 ≤ 5 dias úteis`

O que mede: se o setup funciona como **day trade**, que é o foco do laboratório. São duas condições:

- **Média de pelo menos 2 operações por semana** — senão não é uma rotina de day trade.
- **Intervalo p90 de até 5 dias úteis** — em 90% das vezes, o intervalo entre um dia com operação e o próximo é de no máximo uma semana. Evita setups que operam muito em algumas semanas e somem por meses.

Por que importa: poucas operações por ano deixam a amostra pequena, o resultado demora anos para aparecer e o trader fica parado. Além disso, um setup que segura posição de um dia para o outro deixa de ser day trade (paga swap e corre risco de gap).

REPROVADO
003 (H4): 0,1 operação por semana, com até 99 dias úteis entre operações.

REPROVADO POR POUCO
004.1: 1,6 por semana, p90 de 8 dias úteis (os filtros de tendência e de faixa estreita cortam muitos dias).

Exceção decidida antes: no 003.1, que segurava posição durante a noite (swing), esse critério foi informativo e não eliminatório — e isso foi decidido **antes** de ver os resultados.

+ Métricas que aparecem no relatório (sem limite fixo)

Métrica	O que é	Como ler
Taxa de acerto	% de operações vencedoras	Sozinha não diz nada; olhe junto com o payoff
Payoff	ganho médio ÷ perda média	Acerto 40% precisa de payoff > 1,5 para empatar
Sharpe	retorno médio diário ÷ oscilação, anualizado	> 1 é bom; negativo, perde dinheiro
Sortino	como o Sharpe, mas só pune a oscilação para baixo	Melhor que o Sharpe para setups assimétricos
Drawdown máximo	maior queda do período inteiro	Compare com o quanto você aguentaria perder
Retorno com 1% de risco	resultado acumulado da conta	Inclui juros compostos; depende do período
Comissão US$ 7	sensibilidade a uma conta com comissão	Se vira negativo, a margem é pequena demais

COMO UM SETUP É APROVADO

Todos os 7 critérios, fora da amostra, com custos. Mesmo aprovado, o próximo passo não é a conta real: é rodar em **conta demo** pelo tempo necessário para comparar o resultado real com o do backtest. Educação e pesquisa de método — não é recomendação de investimento.